

Modul: GEO 418 „Hyperspektrale Fernerkundung“

Leitung: Dr. Martin Bachmann

Abschlussbericht

vorgelegt von:

Maximilian Nestler
Studiengang: Geoinformatik (M.Sc.)
Semester: 3
Matr.-Nr.: 159551
E-Mail: maximilian.nestler@uni-jena.de

Abgabedatum: 31.05.2021

Inhalt

1 Einleitung	1
2 Beschreibung der spektralen Variabilität von Vegetation	1
2.1 Beschreibung der spektralen Unterschiede von gesunder und kranker Vegetation	1
2.2 Ursachen der spektralen Unterschiede	3
3 Zusammenhang von LAI und Spektralmessungen	4
3.1 Auswirkungen des LAI auf die Spektren	4
3.2 Zusammenhang zwischen LAI und Vegetationsindizes	5
4 Regression der Bodenfeuchte	7
5 Literatur	12

1 Einleitung

Die hyperspektrale Fernerkundung basiert auf der Analyse der von der Erdoberfläche reflektierten Strahlung. Im Unterschied zur multispektralen Fernerkundung wird diese Analyse durch schmale, spektral benachbarte und sich überlappende Kanäle ermöglicht. So decken hyperspektrale Scanner heute große Bereiche der Erdoberfläche mit einer hohen zeitlichen, geometrischen und spektralen Auflösung ab (J. M. Bioucas-Dias et al. 2013). Während in der Vergangenheit häufig hyperspektrale Feld- und Labormessungen vorgenommen wurden, öffnete die Entwicklung der luftgestützten hyperspektralen Fernerkundung der Wissenschaft neue Möglichkeiten. Dabei misst die hyperspektrale Fernerkundung meist im sichtbaren (VIS) sowie im Infrarot-Bereich (NIR und SWIR, Nahes Infrarot und kurzwelliges Infrarot) (Goetz 2009). Durch die Analyse der unterschiedlichen Spektren von beispielweise Mineralien, Gesteinen, Böden und Vegetation können fundierte wissenschaftliche Aussagen über die Beschaffenheit des Materials getätigt werden, ohne selbst Messungen vornehmen zu müssen. Außerdem können mit ihrer Hilfe biologische und chemische Prozesse auf der Erdoberfläche quantifiziert und somit detektiert werden (Goetz 2009).

Diese Arbeit soll sich mit der spektralen Analyse verschiedener Vegetationsarten und der Einfluss von Wasser auf Bodenproben und deren spektrale Signaturen beschäftigen. Dabei wurden die Messungen zur Beschreibung der spektralen Variabilität im Labor getätigt. Zur Verfügung stehen spektrale Messungen von Blättern drei unterschiedlicher Vegetationsspezies: Linde, Kastanie und wilder Wein (Kapitel 2). Um den Zusammenhang des LAI mit Vegetationsindizes zu betrachten, wurden LAI-Serien aus Spektralmessungen berechnet (Kapitel 3). Für die Durchführung einer PLS-Regression, um den Einfluss von Wasser auf Bodenproben zu analysieren, wurde ein Datensatz mit spektralen Messungen von Bodenproben zur verwendet (Kapitel 4).

2 Beschreibung der spektralen Variabilität von Vegetation

Dieses Kapitel beschreibt die spektrale Variabilität von unterschiedlichen Vegetationsarten. Die im Vorfeld gemessenen Reflektionskurven, welche allesamt Auffälligkeiten in bestimmten Wellenlängenbereichen aufweisen, werden beschrieben. Im Anschluss sollen Ursachen für die genannten Auffälligkeiten gefunden werden.

2.1 Beschreibung der spektralen Unterschiede von gesunder und kranker Vegetation

Abbildung 1 zeigt den mittleren Reflexionsgrad von einem Blatt der Linde, Kastanie und Wilder Wein zwischen $0,4\ \mu\text{m}$ und $2,5\ \mu\text{m}$. Die helleren Farbtöne zeigen die jeweilige Standardabweichung für jede dieser Arten. Ein Reflektanzwert von beispielweise 3000 entspricht dabei einem Reflexionsvermögen von 30%.




Abbildung 1: Mittlere Reflektanzwerte von Linde (blau), Kastanie (rot) und Wildem Wein (grün) sowie deren Standardabweichungen (heller Farbton)

Linden- und Weinblätter zeigen im sichtbaren Bereich (VIS) des Spektrums ($0,4 \mu\text{m} - 0,7 \mu\text{m}$) einen *Green Peak* bei $\sim 0,55 \mu\text{m}$. Das bedeutet, dass der Reflexionsgrad im grünen Spektralbereich höher ist als im blauen ($0,4 \mu\text{m}$) und roten ($0,7 \mu\text{m}$). Außerdem besitzen beide die sogenannte *Red Edge* im Nahen Infrarot (NIR). Diese zeichnet sich durch einen starken Anstieg des Reflexionsgrades (ungefähr zwischen $0,7 \mu\text{m}$ und $0,8 \mu\text{m}$) im NIR aus. Das Kastanienblatt weist diese beschriebenen Auffälligkeiten nicht auf. Der Reflexionsgrad steigt im VIS stetig an und zeigt weder *Green Peak* noch *Red Edge*.

Alle drei Arten zeigen hohe Reflexionsgrade im NIR zwischen $0,7 \mu\text{m}$ und $1,3 \mu\text{m}$. Am höchsten ist dieser beim Blatt des Wilden Weines zu erkennen. Außerdem sind die sogenannten Wasserabsorptionsbanden sowohl im NIR als auch im SWIR (*Shortwave Infrared*, dt. kurzwelliges Infrarot) gut sichtbar. Zu sehen sind diese in den Bereichen $\sim 1,4 \mu\text{m}$ bis $1,5 \mu\text{m}$, $1,9 \mu\text{m}$ und $2,5 \mu\text{m}$. Am ausgeprägtesten sind die Wasserabsorptionen beim Wilden Wein und der Linde, während das Kastanienblatt deutlich weniger sinkende Reflexionsgrade aufweist. Zwischen diesen Bereichen zeigen alle drei Kurven ähnliche Verläufe, wobei das Kastanienblatt ab $1,5 \mu\text{m}$ den höchsten Reflexionsgrad aufweist. Auffällig ist, dass die Kurven vom Wilden Wein und der Linde ähnlich sind, der Wilde Wein allerdings stetig höhere Reflektionswerte zeigt. Die Variabilität (Standardabweichung) ist beim Wilden Wein am geringsten. Das Lindenblatt besitzt im nahen Infrarot eine erhöhte Variabilität. Demgegenüber zeigt die Spektralkurve des Kastanienblattes – ausgenommen im VIS – deutlich erhöhte Standardabweichungen.

2.2 Ursachen der spektralen Unterschiede

Die in 2.1 beschriebenen Auffälligkeiten der Spektralkurven drei unterschiedlicher Pflanzenarten sollen nun interpretiert und mögliche Ursachen gesucht werden. Dabei ist zu aller erst festzuhalten, dass laut Riedel (2018) die Ursachen für die unterschiedlichen Verläufe der Spektralkurven Pigmente (z.B. Chlorophyll oder Carotin), Mesophyll und Wasser sind. Dies wird durch die Abbildung 2 veranschaulicht.




Abbildung 2: Spektrale Signatur von gesunder, grüner Vegetation. Aus: Riedel (2018)

Laut Sonobe und Wang (2017) zeigen die Unterschiede des Reflexionsgrades im *Green Peak* und der *Red Edge*, ob die betrachtete Vegetation gesund oder gestresst ist.

Dementsprechend lässt sich die Vitalität der Blätter vom Kurvenverlauf ableiten. Der ausgeprägte *Green Peak* der Blätter des Wilden Weins und der Linde zeigt, dass diese Chlorophyll beinhalten. Chlorophyll absorbiert im blauen und roten Spektralbereich Licht, um die Fotosynthese betreiben zu können. Das Spektrum gesunder Vegetation, welche Chlorophyll beinhalten, ist in Abbildung 2 („Chlorophyll Absorption“) illustriert. reflektiert dementsprechend grünes Licht stärker, weshalb gesunde Vegetation für das menschliche Auge grün erscheint. Des weiteren ist die *Red Edge* bei beiden Blättern deutlich zu erkennen, was wiederum ein Zeichen für vitale (grüne) Vegetation ist (Kumar et al. 2002).

Dem entgegen ist keine der beschriebenen Charakteristika für das Kastanienblatt zu verzeichnen. Diese zeigt einen linearen Anstieg des Reflexionsgrades im sichtbaren Bereich, ohne *Green Peak* oder *Red Edge*. Das erhöhte Reflexionsvermögen im roten Bereich des Spektrums erfolgt, da im Herbst das in den Blättern befindliche Chlorophyll abgebaut wird. Aus diesem Prozess heraus werden anderen Pigmente (wie z.B. Carotin, Anthocyanin & Xanthophyll) im Blatt sichtbar (Ghosh 2010). Deshalb wird das Kastanienblatt für das menschliche Auge nicht mehr grün, sondern in Orange- oder Rottönen erscheinen, da sich das Reflexionsvermögen im roten Bereich erhöht hat.

Die beim Wilden Wein und der Linde ausgeprägten Wasserabsorptionsbanden zeigen, dass beide Blätter einen hohen Wassergehalt aufweisen, während diese bei der Kastanie nur schwach ausgeprägt sind. Somit lässt sich schließen, dass das Kastanienblatt einen niedrigen Wassergehalt beinhaltet und somit welk ist.

Desweiteren hat die Zellstruktur einen Einfluss auf die Spektren. So zeigt Clark et al. (2005), dass die hohen Reflexionsgrade im *NIR-Plateau* (siehe Abbildung 2) durch das in den Blättern enthaltene Mesophyll hervorgerufen werden. Sowohl das Spektrum des Wein- als auch des Lindenblattes zeigt das NIR-Plateau deutlich.

Zusammenfassend lässt sich schließen, dass sich grüne und welke Blätter in nahezu allen Spektralbereichen unterscheiden. Vor allem im sichtbaren Bereich des Spektrums (VIS) sind große Differenzen zwischen gesunden (Wilder Wein und Linde) und welken (Kastanie) zu sehen. Zudem zeigen die Wasserabsorptionsbanden deutliche Unterschiede im Reflexionsgrad, welche zeigen, dass der Wassergehalt der gesunden Blätter deutlich höher ist als der des welken Kastanienblattes.

3 Zusammenhang von LAI und Spektralmessungen

Das folgende Kapitel stellt unterschiedliche LAI-Serien dar und soll versuchen, die spektralen Unterschiede zwischen diesen Serien zu erklären. Außerdem soll der Zusammenhang zwischen dem LAI und dem NDVI anhand einer Abbildung erklärt werden.

3.1 Auswirkungen des LAI auf die Spektren

Abbildung 3 veranschaulicht die fünf unterschiedlichen LAI-Serien sowie das Spektrum einer Bodenprobe. Anhand der Abbildung lässt sich schließen, dass sich der Reflexionsgrad mit steigendem LAI erhöht. Diese Beobachtung zeigt sich besonders eindeutig im NIR-Bereich ($0,7\ \mu\text{m} - 1,3\ \mu\text{m}$), wo der Reflexionsgrad von $\sim 0,25$ (LAI 0,5) auf $\sim 0,55$ (LAI 4) steigt.

Außerdem fällt auf, dass die Kurve vom LAI 0,5 im VIS dem Verlauf eines Bodens ähnelt. Es ist kein *Green Peak* und keine *Red Edge* zu sehen. Ab einem LAI von 1 zeigt sich sowohl der *Green Peak* als auch die *Red Edge*. Möglicherweise zeigt sich hier ein Sättigungseffekt, welcher durch die vergleichsweise niedrige Sensitivität des Reflexionsvermögens im roten Band zurückzuführen ist (Zhen et al. 2021). Sämtliche LAI-Serien zeigen Wasserabsorptionsbanden, wobei diese mit steigendem LAI auch stärker ausgeprägt sind.




Abbildung 3: Spektren des Bodens & der LAI-Serien

3.2 Zusammenhang zwischen LAI und Vegetationsindizes

Um den Zusammenhang von LAI und Vegetationsindizes zu untersuchen, wurden zwei unterschiedliche Indizes berechnet, die im Folgenden vorgestellt werden.

Der NDVI (*Normalized Difference Vegetation Index*) ist der verbreitetste Vegetationsindex und beschreibt die Differenz der Menge der Reflektion im roten und nahen Infrarotbereich des Lichts (Matsushita et al. 2007). Die folgende Formel zeigt die Berechnung dieses Index:

$$NDVI = \frac{NIR_{800} - R_{670}}{NIR_{800} + R_{670}} \quad (1)$$

Außerdem wurde der SAVI (Soil Adjusted Vegetation Index) berechnet. Dieser basiert auf dem NDVI, besitzt allerdings einen Korrekturfaktor L , welcher Einflüsse des Bodens minimieren soll (D. Haboudane et al. 2008). Dieser wird wie folgt berechnet:

$$SAVI = \frac{NIR_{800} - R_{670}}{NIR_{800} + R_{670} + L} (1 - L) \quad (2)$$

Zur Berechnung wurde der empfohlene Wert von $L = 0,5$ einbezogen (Huete 1988).

Die in Abbildung 4 dargestellte Kurve soll den Zusammenhang von LAI und NDVI beziehungsweise SAVI veranschaulichen. Sie zeigt einen starken Anstieg des NDVI von 0,15 (Boden) bis 0,75 bei einem LAI von 1. Im weiteren Verlauf der Kurve erhöht sich der NDVI nur noch leicht (LAI 2 mit NDVI = 0,8; LAI 3 mit NDVI = 0,85; LAI 4 mit NDVI = 0,82). Dieses

Muster deutet auf die schon in 3.1 beschriebene Sättigung des LAI sowie des NDVI bei steigender Biomasse hin. Diese Einschätzung wird in unterschiedlichen Veröffentlichungen bestätigt, wie beispielsweise von Zhao et al. (2012) und Xu et al. (2020). Carlson und Ripley (1997) unterstreichen weiterhin die beobachtete Sättigung des NDVI ab einem LAI > 2. Der SAVI folgt einem ähnlichen Muster. Auffällig ist der deutlich leichtere Anstieg des SAVI mit steigendem LAI. Während der NDVI schon ab einem LAI = 0,5 einen hohen Wert (0,7) verzeichnet, liegt dieser beim SAVI bei etwa 0,3. Fortan steigt dieser stetig an und erreicht bei einem LAI = 3 seinen höchsten Wert (~0,65). Festzuhalten ist, dass die beschriebene Sättigung des NDVI bei niedrigem LAI nicht auf den SAVI zutrifft. Dies ist vermutlich auf den Korrekturfaktor L zurückzuführen (Zhen et al. 2021). Tabelle 1 fasst die oben getroffenen Aussagen zusammen.

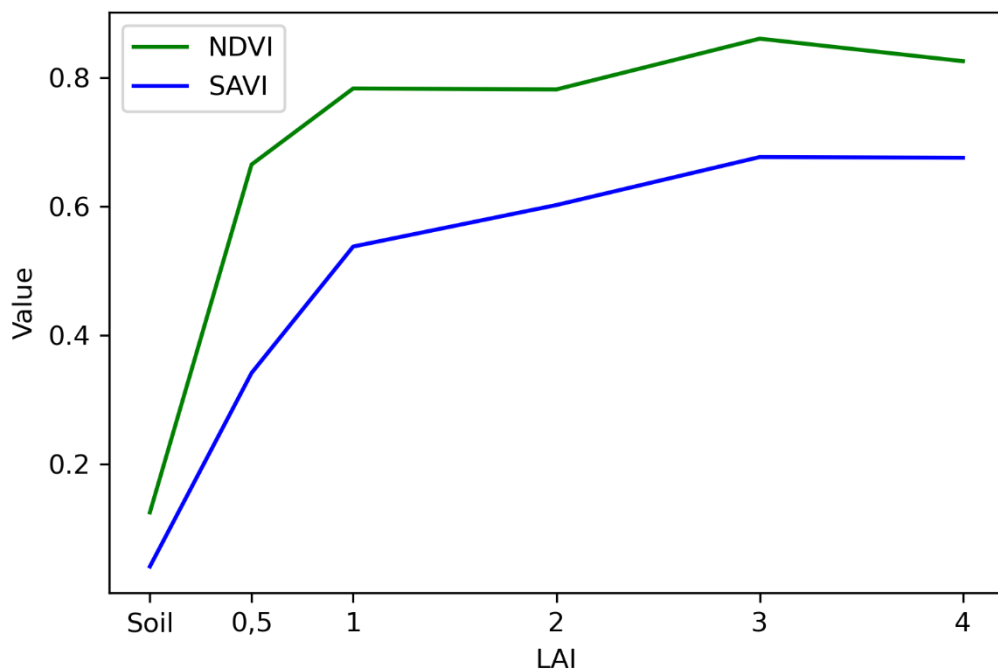


Abbildung 4: Zusammenhang von LAI, SAVI und NDVI

Tabelle 1: Vergleich von NDVI und SAVI im Zusammenhang mit steigendem LAI sowie deren Bestimmtheitsmaß (R^2)

LAI	Boden	0,5	1	2	3	4	R^2
NDVI	0,1250	0,6648	0,7828	0,7814	0,8601	0,8252	0,6458
SAVI	0,0410	0,3412	0,5375	0,6019	0,6764	0,6753	0,7661

Mit steigendem LAI erhöhen sich bei beiden Indizes die jeweiligen Werte. Das entspricht auch der Erwartung, dass mit steigender Vegetationsdichte (LAI) ebenso der jeweilige Wert des Vegetationsindex steigt, da diese sensitiv für gesunde Biomasse sind. Zudem zeigt die Tabelle die schon für niedrige LAI-Werte hohen NDVI-Werte, die im weiteren Verlauf nur noch mäßig steigen und belegen damit die von vielen Wissenschaftlern kritisierte schnelle

Sättigung. Dagegen steigen die SAVI-Werte mit höherem LAI langsamer an, eine Sättigung tritt erst bei deutlich höherem LAI ein. Dieses Muster belegt ebenso der R^2 -Wert. Dieser zeigt für den NDVI einen deutlich niedrigeres Bestimmtheitsmaß (0,64) als für den SAVI (0,76). Die niedrigen Indexwerte für die Bodenproben entsprechen der Erwartung und zeigen, dass sich Vegetationsindizes sehr gut zur Trennung von Vegetation und Böden eignen.

4 Regression der Bodenfeuchte

Wasser hat, wie in den Kapiteln zuvor schon festgestellt (z.B. Wasserabsorptionsbanden) einen großen Einfluss auf die spektrale Signatur. In diesem Kapitel soll der Einfluss von Wasser auf Bodenproben mittels einer PLS-Regression untersucht werden (Guebel und Torres 2013). Dazu wurden, wie in Tabelle 2 dargestellt, Bodenproben mittels Sprühstößen Wasser zugeführt. Diese Sprühstöße wurden mit der Zeit weiter erhöht (von trocken bis 49 Sprühstöße). Für jeden aufgezeichneten Sprühstoß wurden jeweils fünf Spektralmessungen vorgenommen.

Tabelle 2: Übersicht der Spektralmessungen und der Anzahl der Sprühstöße (Aus: Bachmann, 2020)

Messung	Anzahl Sprüher insg.
0-4	trocken
5-9	1
10-14	2
15-19	3
20-24	4
25-29	5
30-34	6
35-39	7
40-44	8
45-49	9
50-54	10
55-59	11
60-64	12
65-69	13
70-74	14
75-79	15
80-84	17
85-89	19
90-94	21
95-99	24
100-104	27
105-109	30
110-114	33
115-119	36
120-124	49

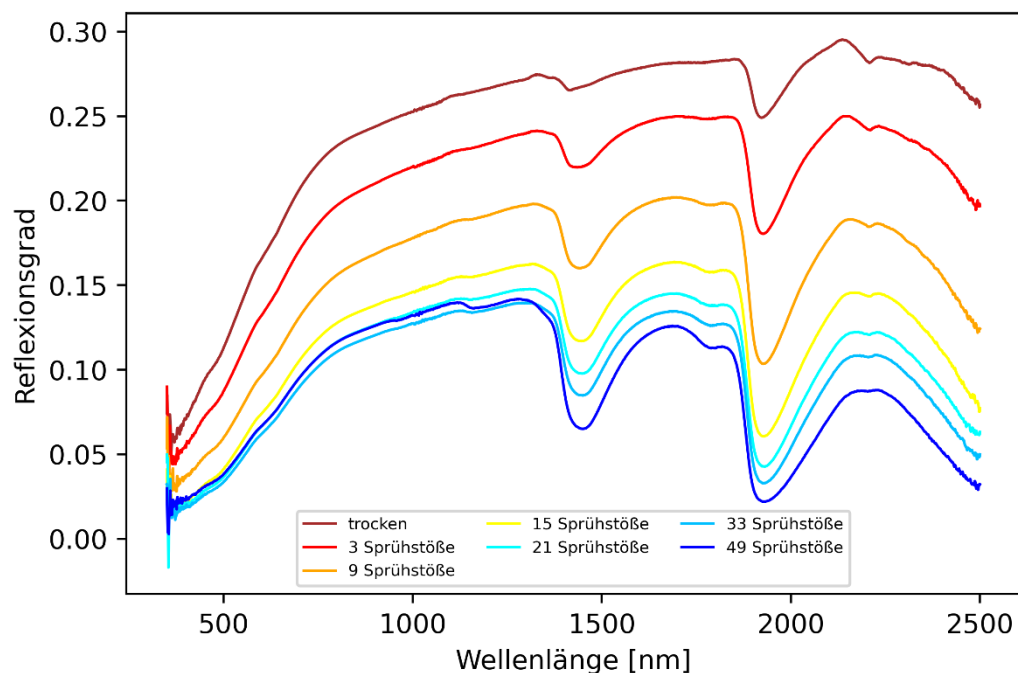


Abbildung 5: Spektren ausgewählter Bodenproben

Die Spektralmessungen der Bodenfeuchtigkeit sind in der Abbildung 5 mittels ausgewählter Sprühstöße dargestellt. Diese zeigt, dass mit steigender Bodenfeuchte der Reflexionsgrad sinkt. Es ist festzustellen, dass die Reflexion zu Beginn (bis 9 Sprühstöße) sehr stark sinkt und im Verlauf immer schwächer abnimmt. Außerdem sind die Wasserabsorptionsbanden umso stärker ausgeprägt, desto höher der Wassergehalt in der Probe ist.

Die PLS-Regressionanalyse wurde hinsichtlich der Anzahl von Sprühstößen (Bodenfeuchte) und den darauf basierenden spektralen Merkmalen durchgeführt. Dabei sollen PLS-Koeffizienten ermittelt werden, da diese den Zusammenhang jedes spektralen Bandes mit der Bodenfeuchte angeben. Dabei wurden unterschiedliche Ansätze und Optimierungen verfolgt, die im Folgenden wiedergegeben werden.

Zur besseren Übersicht werden in Abbildung 6 sämtliche gemessene Spektren aufgeführt. Anzumerken ist, dass die Bänder zwischen 350nm und 550nm herausgeschnitten wurden, da diese verrauscht waren. Der untere Plot stellt die absoluten PLS-Koeffizienten dar. Stark positive oder negative Werte deuten dabei auf einen Zusammenhang hin, Werte nahe Null bedeuten einen geringen oder gar keinen Zusammenhang.

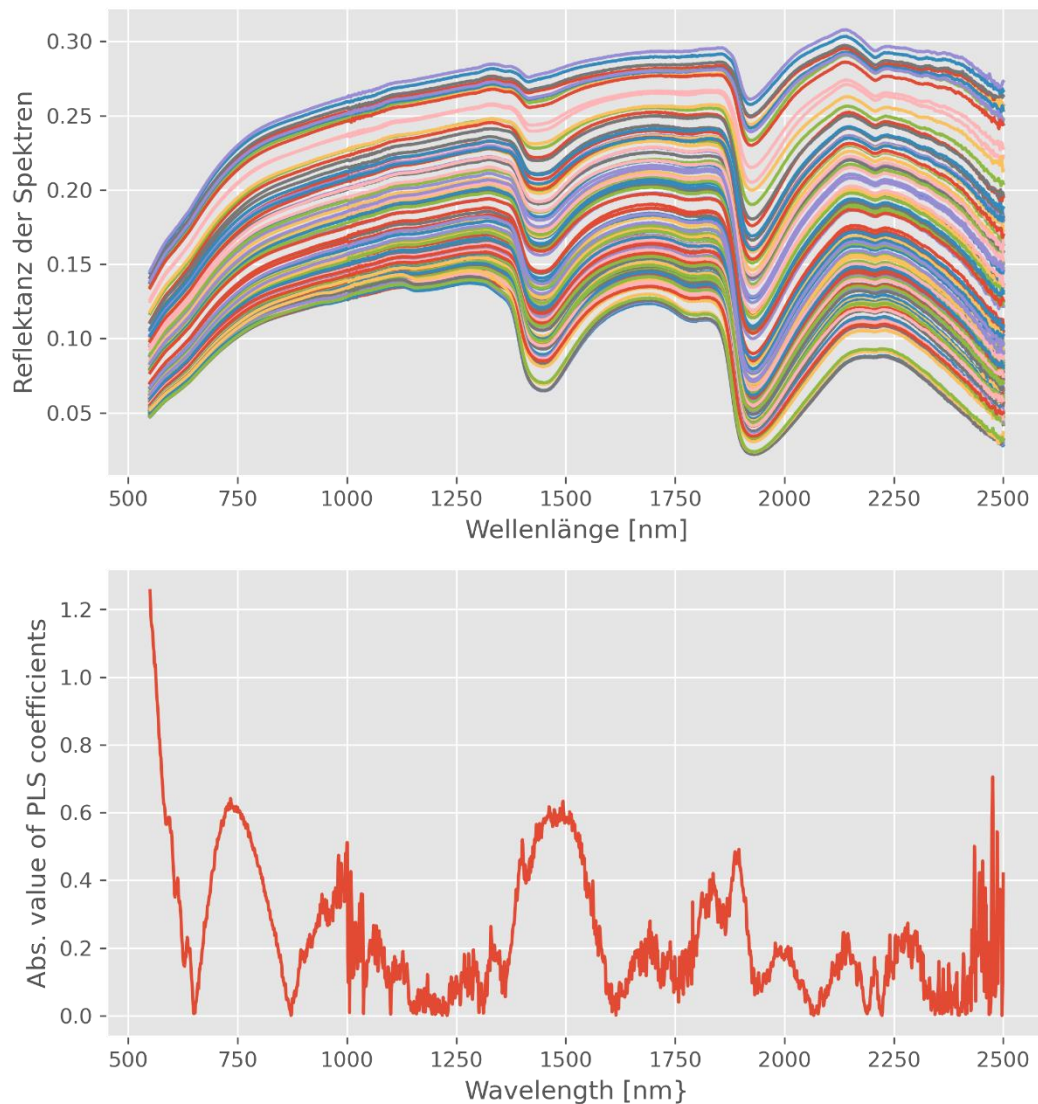


Abbildung 6: Oben: Darstellung sämtlicher detektierter Spektren, Bereich 350nm bis 550nm aufgrund von Rauschen herausgeschnitten, Unten: Darstellung der PLS-Koeffizienten

Die untere Abbildung (Abbildung 6) zeigt dabei deutlich, dass die Spektralbereiche um 750nm, 1000nm, 1500nm, 1900nm und 2450nm Werte von über 0,5 aufweisen. Somit eignen sich diese Spektralbereiche gut, um die Bodenfeuchtigkeit zu beschreiben, weshalb diese potenziell für die PLS-Regression geeignet sind.

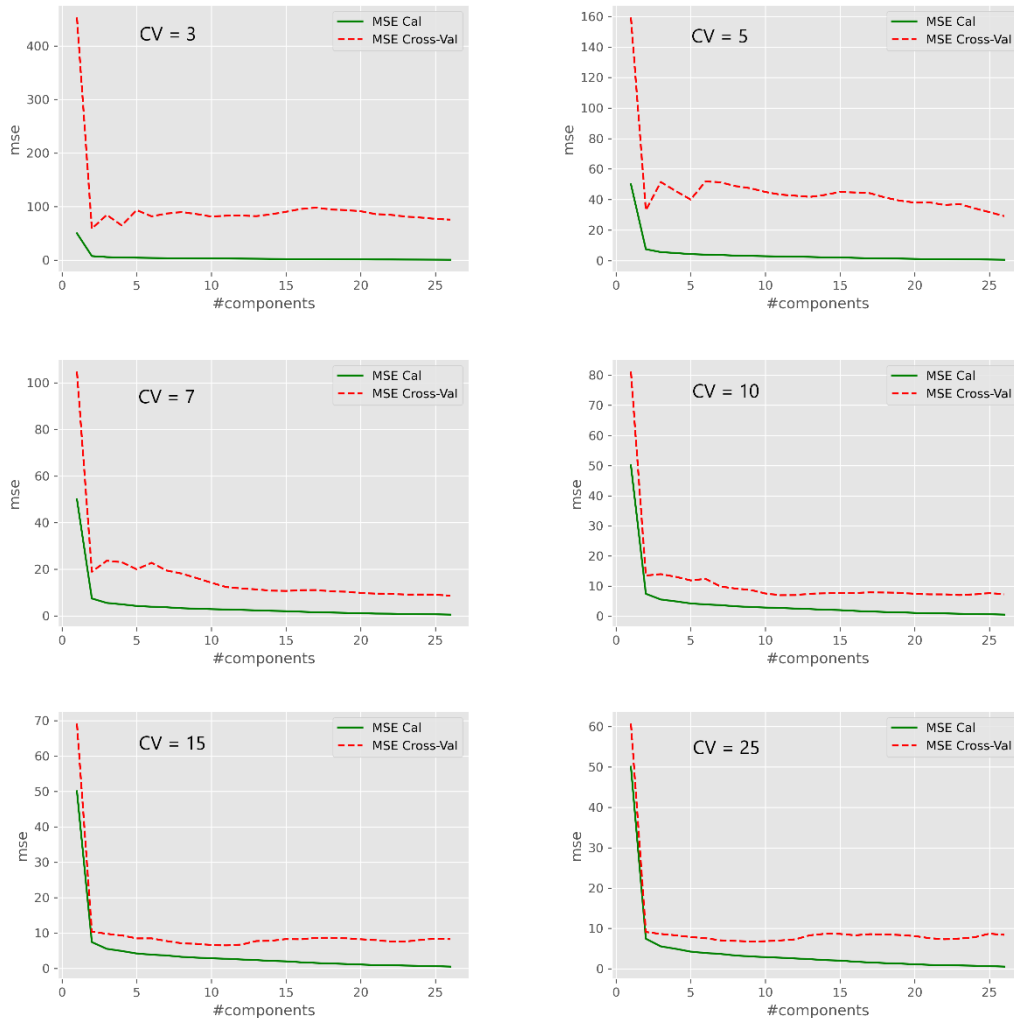


Abbildung 7: Übersicht aller verwendeten Kreuzvalidierungswerte (MSE)

Abbildung 7 versucht das spezielle Verhalten des mittleren Fehlers (MSE) in Abhängigkeit von den Komponenten darzustellen. Es wurden dabei unterschiedliche Kreuzvalidierungskoeffizienten (CV) untersucht. Hierbei ist auffällig, dass schon ab wenigen Komponenten (2-3) der MSE massiv absinkt. Dies ist sowohl bei einem CV von 3 der Fall als auch bei einem CV von 25. Da bei einem CV-Wert < 10 der MSE trotz stark sinkenden Werten immer noch hoch ist und ein CV-Wert von 10 deutlich niedrigere MSE-Werte bei nur wenigen Komponenten zeigt, wird dieser Wert für die anschließende PLS-Regression genutzt.

Die folgenden Abbildungen 8 und 9 zeigen die Ergebnisplots der PLS-Regression, welche das gesamte Spektrum der Messungen (550nm bis 2500nm) einbezogen hat. Diese wurde mit dem oben erwähnten Wert für den Kreuzvalidierungskoeffizienten = 10 durchgeführt. Das PLS-Modell ermittelte dabei einen Kalibrations- R^2 -Wert von 0,981. Der R^2 -CV-Wert wird mit 0,952 angegeben. Außerdem wird ein Kalibrations-MSE von 2,73 und ein MSE-CV von 6,981 angegeben. Abbildung 8 zeigt dabei, dass elf Komponenten nötig sind, um mittels des Modells die Bodenfeuchte am präzisesten vorherzusagen, da hier der niedrigste MSE-Wert erreicht wird. Das Modell kann hierbei die Bodenfeuchte in einem hohen Maße vorhersagen, was auch der hohe R^2 -CV-Wert zeigt.




Abbildung 8: Geschätzte Anzahl der PLS-Komponenten




Abbildung 9: Plot der Wasserl-Vorhersage des Modells gegen das gemessene Wasser

Zusammenfassend lässt sich sagen, dass sowohl die Spektren als auch das Regressionsmodell einen eindeutigen Zusammenhang zwischen Bodenfeuchtigkeit und Reflexionsgrad zeigt. Je mehr Wasser eine Bodenprobe enthält, desto niedriger ist der ermittelte Reflexionsgrad. Abbildung 9 unterstreicht dabei, dass das Modell, welches aus den Reflexionsmerkmalen errechnet wurde, den Wassergehalt sehr gut vorhersagen kann.

5 Literatur

- Carlson, Toby N.; Ripley, David A. (1997): On the relation between NDVI, fractional vegetation cover, and leaf area index. In: *Remote Sensing of Environment* 62 (3), S. 241–252. DOI: 10.1016/S0034-4257(97)00104-1.
- Clark, Matthew; Roberts, Dar; Clark, David (2005): Hyperspectral discrimination of tropical rain forest tree species at leaf to crown scales. In: *Remote Sensing of Environment* 96, S. 375–398. DOI: 10.1016/j.rse.2005.03.009.
- D. Haboudane; N. Tremblay; J. R. Miller; P. Vigneault (2008): Estimation of Plant Chlorophyll using Hyperspectral Observations and Radiative Transfer Models: Spectral Indices Sensitivity and Crop-Type Effects. In: IGARSS 2008 - 2008 IEEE International Geoscience and Remote Sensing Symposium. IGARSS 2008 - 2008 IEEE International Geoscience and Remote Sensing Symposium (3), III - 569-III - 572.
- Frank Riedel (2018): Der Einsatz hyperspektraler Fernerkundungsdaten zur Analyse schwermetallbedingter Boden- und Pflanzenbelastungen Der Einsatz hyperspektraler Fernerkundungsdaten zur Analyse schwermetallbedingter Boden- und Pflanzenbelastungen in einem Auenökosystem unter besonderer Berücksichtigung der Feinmorphologie. Dissertation. Martin-Luther-Universität Halle-Wittenberg, Halle. Naturwissenschaftliche Fakultät III. Online verfügbar unter https://opendata.uni-halle.de/bitstream/1981185920/13644/1/Dissertation_Riedel_Frank_Hyperspektrale_FE_Schwermetalle_Flaussauen_2018_11_07.pdf, zuletzt geprüft am 20.05.2021.
- Ghosh, Dipanjan (2010): Secrets of Plant Pigments. In: *Scienc Reporter* (47), S. 29–33.
- Goetz, Alexander F.H. (2009): Three decades of hyperspectral remote sensing of the Earth: A personal view. In: *Remote Sensing of Environment* 113, S5-S16. DOI: 10.1016/j.rse.2007.12.014.
- Guebel, Daniel V.; Torres, Néstor V. (2013): Partial Least-Squares Regression (PLSR). In: Werner Dubitzky, Olaf Wolkenhauer, Kwang-Hyun Cho und Hiroki Yokota (Hg.): *Encyclopedia of Systems Biology*. New York, NY: Springer New York, S. 1646–1648.
- Huete, A.R (1988): A soil-adjusted vegetation index (SAVI). In: *Remote Sensing of Environment* 25 (3), S. 295–309. DOI: 10.1016/0034-4257(88)90106-X.
- J. M. Bioucas-Dias; A. Plaza; G. Camps-Valls; P. Scheunders; N. Nasrabadi; J. Chanussot (2013): Hyperspectral Remote Sensing Data Analysis and Future Challenges. In: *IEEE Geoscience and Remote Sensing Magazine* 1 (2), S. 6–36. DOI: 10.1109/MGRS.2013.2244672.
- Kumar, Lalit; Schmidt, Karin; Dury, Steve; Skidmore, Andrew (2002): Imaging Spectrometry and Vegetation Science. In: S. 111–155.
- Matsushita, Bunkei; Yang, Wei; Chen, Jin; Onda, Yuyichi; Qiu, Guoyu (2007): Sensitivity of the Enhanced Vegetation Index (EVI) and Normalized Difference Vegetation Index (NDVI) to Topographic Effects: A Case Study in High-density Cypress Forest (*Sensors*, 7).
- Sonobe, Rei; Wang, Quan (2017): Towards a Universal Hyperspectral Index to Assess Chlorophyll Content in Deciduous Forests. In: *Remote Sensing* 9 (3), S. 191. DOI: 10.3390/rs9030191.

Xu, Dandan; An, Deshuai; Guo, Xulin (2020): The Impact of Non-Photosynthetic Vegetation on LAI Estimation by NDVI in Mixed Grassland (Remote Sensing, 12).

Zhao, J.; Li, J.; Liu, Q.; Yang, L. (2012): A preliminary study on mechanism of LAI inversion saturation. In: *ISPRS - International Archives of the Photogrammetry, Remote Sensing and Spatial Information Sciences XXXIX-B1*, S. 77–81. DOI: 10.5194/isprsarchives-XXXIX-B1-77-2012.

Zhen, Zhijun; Chen, Shengbo; Yin, Tiangang; Chavanon, Eric; Lauret, Nicolas; Guilleux, Jordan et al. (2021): Using the Negative Soil Adjustment Factor of Soil Adjusted Vegetation Index (SAVI) to Resist Saturation Effects and Estimate Leaf Area Index (LAI) in Dense Vegetation Areas (Sensors, 21).